Procesamiento del Lenguaje Natural — Informe general (Prácticas 1, 2 y 3)

Grupo 10 · UNR · Tecnicatura Universitaria en Inteligencia Artificial. Aldana Desiré Sánchez, Damián Grimaldi, Lisandro Odisio Martinelli, Diego Añaños, Adriano Marzol.

Idea general

Las tres prácticas son un recorrido sobre un mismo dominio, los libros de Lectulandia: **(1)** se construye un corpus, **(2)** se representan sus sinopsis como vectores y se evalúa la búsqueda semántica, **(3)** se audita un catálogo grande de 8.747 libros y se lo usa para recomendar según las preferencias de un lector.

Práctica	Qué se hizo	Resultado principal
1. Extracción de texto	Scraper con Playwright y BeautifulSoup sobre la categoría Aventuras: título, autores, géneros, serie y sinopsis, con guardado incremental y pausas entre pedidos.	Corpus *libros.csv* de 400 libros (dos corridas de 200). Los *id* se repiten; la clave es la URL.
2. Embeddings y búsqueda	TF-IDF, Word2Vec propio (12 modelos), SBW preentrenado, modelo de oraciones multilingüe y Doc2Vec; evaluación con 11 consultas propias (precision@k, acierto@k).	Con acierto@5: TF-IDF 0,91 · PV-DBOW 0,82 · oraciones 0,64 · SBW 0,45 · Word2Vec 0,36 · azar ≈ 0.
3. Recomendador	Limpieza del catálogo, auditoría de contaminación (regex, idioma, NER, clasificadores TF-IDF y embeddings, copias), preferencias de un lector, clasificadores y recomendaciones con resumen.	611 libros sospechosos descartados; catálogo limpio de 8.032. Combinación de detectores: precisión 0,88 y recall 1,00.

Práctica 1 — Corpus

El scraper recorre las páginas de la categoría, visita cada ficha y guarda los datos de a 10 registros para no perder trabajo si se interrumpe. No descarga libros, solo metadatos y sinopsis públicas. Todos los libros tienen sinopsis (mediana de 132 palabras) y 226 pertenecen a una serie. Limitaciones: depende del HTML del sitio, la validación es mínima y hay una sinopsis en gallego. Volver a ejecutarlo agrega libros al CSV, y la Práctica 2 usa una copia.

Práctica 2 — Embeddings

Se usaron dos versiones del texto: limpio (minúsculas, sin acentos ni stopwords) para TF-IDF, Word2Vec y SBW, y crudo para el modelo de oraciones, que fue entrenado con texto natural. **TF-IDF fue el más fuerte** (precision@1 0,73; acierto@5 0,91), porque las consultas se escribieron a partir de las sinopsis y comparten vocabulario con ellas. Entre los embeddings, **Doc2Vec PV-DBOW** quedó primero (precision@1 0,82, una consulta más que TF-IDF), estable con distintas semillas, y superó al promedio de Word2Vec. El modelo de oraciones lee solo 128 tokens y trunca 315 de las 400 sinopsis (44 % del texto). **Ningún modelo resolvió la consulta sin palabras compartidas**, por lo que los embeddings no mostraron la ventaja esperada. Con solo 11 consultas, cada una mueve los promedios unos 9 puntos: las diferencias chicas son indicios, no resultados firmes. No se hicieron las partes E y F (PostgreSQL con pgvector), que los docentes indicaron como no necesarias.

Práctica 3 — Auditoría y recomendador

Limpieza: de 8.747 registros quedaron 8.643 (1 sin sinopsis, 98 sinopsis duplicadas, 5 versiones de una misma obra unidas; se separaron series como «Conversaciones con Dios I y II»). **Auditoría** (prueba de 150 libros, 30 contaminados):

Detector	Precisión	Recall	Detector	Precisión	Recall
Regex normalizada	1,00	0,63	Clasificador embeddings	1,00	0,87
Idioma por oración	0,89	0,27	Libros copiados	1,00	0,10
Clasificador TF-IDF	0,91	0,97	**Combinación (OR)**	**0,88**	**1,00**

Cada falso positivo es un libro legítimo que nunca podrá recomendarse (4 sobre 120 en la prueba). **Recomendador:** con 107 libros recorridos (62 unos, 38 ceros, 7 abstenciones; 80 de entrenamiento y 20 de prueba), el F1 de la clase 1 fue 0,57 (TF-IDF) y 0,67 (embeddings); en validación cruzada, 0,64±0,10 y 0,63±0,11. Para recomendar, precision@5 fue 0,60 (TF-IDF), 0,40 (embeddings) y 0,40 (similitud con el perfil); el azar da 0,60. **Las valoraciones fueron simuladas por el código (60 % de 1, 30 % de 0, 10 % de vacío), no hechas por una persona**; los comentarios del lector también. Por eso las métricas de recomendación solo comprueban que el procedimiento funciona y no miden calidad.

Conclusiones y límites

• En detección de contaminación, la representación importa: TF-IDF atrapa cadenas literales (URL disimuladas) y los embeddings dan más precisión; combinados se cubre todo. En preferencias no hubo diferencias medibles. • El mismo patrón se repite en las dos prácticas: **TF-IDF es una línea de base difícil de superar** cuando el vocabulario se comparte. • Límites comunes: conjuntos chicos (11 consultas, 20 libros de prueba), evaluación armada por el propio grupo y, en la Práctica 3, etiquetas simuladas. • Pendiente: repetir el paso 3 con un lector real.

Preguntas del TP3

1. Detectores y costo de un falso positivo. Cinco detectores: *regex normalizada* (enlaces y correos, incluso disimulados con homoglifos, letras separadas o caracteres invisibles); *idioma por oración* (mensajes en inglés o portugués); *clasificador TF-IDF* (promoción sin enlaces y cadenas literales); *clasificador de embeddings* (frases nuevas de igual sentido); y *libros copiados* (sinopsis robadas de otro libro de distinto autor). Un falso positivo elimina un libro

legítimo, que ya no podrá recomendarse: la combinación marcó 4 legítimos de 120 en la prueba. Marcar todo no sirve.

2. Qué es interes y quién valoró. Responde «¿Me interesaría leer este libro?»: 1 = sí, 0 = no, vacío = no puede decidir (se conserva como abstención, no como 0). **No lo valoró una persona:** lo simuló el código con semilla fija (60 % de 1, 30 % de 0, 10 % de vacío).

3. TF-IDF contra embeddings. Al detectar contaminación se fijó la precisión ≈ 0,90 con *precision_recall_curve* y se comparó el recall: 0,97 (TF-IDF) contra 0,87 (embeddings, con precisión 1,00); TF-IDF vio 3 libros que los embeddings no, casi todos URL disimuladas. Al clasificar preferencias se compararon F1 de la clase 1 en prueba (0,57 contra 0,67) y en validación cruzada repetida (0,64±0,10 contra 0,63±0,11). **La diferencia fue mayor en la detección**, porque ahí hay una señal real que cada representación capta de otra forma; en las preferencias, con etiquetas aleatorias y 20 libros, es ruido.

4. ¿Algún clasificador mejoró a la similitud? No de forma demostrable. precision@5: TF-IDF 0,60, embeddings 0,40, similitud con el perfil 0,40 y azar 0,60. TF-IDF superó a la similitud por un libro, pero apenas iguala al azar; con 5 libros, un acierto vale 0,20.

5. Error y límites. Errores: *Una vida en palabras* fue un falso negativo de los embeddings; la combinación dejó pasar un mensaje con correo («ventas@…test») y la entidad «pdf» aparece en el perfil, señal de contaminación residual. Límites: valoraciones simuladas, solo 20 libros de prueba, un único lector, y una muestra enriquecida (20 % contaminados) que no cubre todas las variantes del catálogo.

Uso de asistentes de IA

Se usaron Claude (a través de Claude Code) y, de forma limitada, otro asistente para comprender conceptos, programar y depurar los notebooks, proponer parte de los relevantes de la Práctica 2 (elegidos después de ver algunos rankings, lo que limita la validez de esa evaluación), simular al lector en la Práctica 3 y redactar este informe a partir de los resultados ejecutados.