TP3 · Recomendador personalizado de libros — Informe

Procesamiento del Lenguaje · UNR · Tecnicatura Universitaria en Inteligencia Artificial. Integrantes: Aldana Desiré Sánchez, Damián Grimaldi, Lisandro Odisio Martinelli, Diego Añaños, Adriano Marzol.

1. Detectores de la auditoría, tipos de contaminación y costo de un falso positivo

Evaluamos cada detector sobre la parte de prueba de la muestra (150 libros, 30 contaminados; división 70/30, *random_state*=42, estratificada). El catálogo tenía 8.747 registros; tras el paso 1 quedaron 8.643 (1 sin sinopsis, 98 sinopsis duplicadas, 5 versiones de una misma obra unidas).

Detector	Qué detecta bien	Precisión	Recall
Regex (URL, correo, teléfono) tras normalizar	Enlaces y correos, también los disimulados (letras separadas, «[.]», homoglifos cirílicos, caracteres invisibles). No ve texto promocional sin enlace.	1,00	0,63
Idioma por oración (≥8 palabras, prob. ≥0,90)	Mensajes en inglés o portugués dentro de una sinopsis en español. Sobre la sinopsis completa el idioma es siempre «es» (recall 0).	0,89	0,27
Clasificador de oraciones TF-IDF (n-gramas de caracteres)	Promoción sin enlaces y cadenas literales; umbral 0,327 elegido para precisión 0,90 en desarrollo.	0,91	0,97
Clasificador de oraciones con embeddings	Frases nuevas con el mismo sentido; umbral 0,778.	1,00	0,87
Libros copiados (coseno + Jaccard, autores distintos)	Libros inventados que copian una sinopsis; se marca solo la copia (la sinopsis más larga del par).	1,00	0,10
Combinación (OR)	Un libro es sospechoso si lo marca alguno.	**0,88**	**1,00**

Costo de un falso positivo: un libro legítimo marcado se elimina del catálogo y nunca podrá recomendarse. La combinación marcó 4 legítimos sobre 120 en la prueba (3,3 %). En el catálogo completo se marcaron 611 libros (7,1 %); como la muestra está enriquecida (20 % contaminados) y el catálogo real tiene menos, la precisión allí probablemente sea menor y se pierdan algunas decenas de libros legítimos. Preferimos ese costo a recomendar spam, pero marcar todo no sería una solución. Los libros marcados por clasificadores no son evidencia concluyente: los umbrales se calibraron con una muestra con solo 88 oraciones positivas.

2. Qué representa interes y quién valoró

interes responde «¿Me interesaría leer este libro?» (1 = sí, 0 = no, vacío = no puede decidir, que se conserva como abstención y no se convierte en 0). **Las valoraciones de este trabajo no las hizo una persona: fueron simuladas por el código** (*SIMULAR_LECTOR* = *True*, semilla 42), con probabilidades 60 % de 1, 30 % de 0 y 10 % de vacío, recorriendo el catálogo limpio mezclado con *sample(frac=1, random_state=42)* hasta reunir al menos 100 válidas y 20 por clase. Resultaron 107 libros recorridos: 62 unos, 38 ceros y 7 abstenciones; división 80 entrenamiento / 20 prueba. Los comentarios del lector en el paso 8 también son simulados y están marcados así en el notebook. Como las etiquetas son aleatorias, no hay un gusto real que el modelo pueda aprender: las métricas de los pasos 6 y 7 no miden calidad de recomendación y sirven solo para verificar el procedimiento. Con un lector real basta poner el interruptor en False.

3. TF-IDF contra embeddings

Contaminación (oraciones, precisión ≈ 0,90 fija): en la prueba, TF-IDF detectó 29 de 30 contaminados (recall 0,97) y embeddings 26 de 30 (0,87), con mayor precisión (1,00 contra 0,91). 3 libros los vio solo TF-IDF (URL disimuladas, «h t t p s : /», «punto example barra …»: cadenas literales) y ninguno solo los embeddings. Los embeddings no superaron a TF-IDF en recall; no medimos por separado las variantes ausentes de la muestra, así que no podemos afirmar que generalicen mejor a frases nuevas. La comparación TF-IDF por palabras (recall 0,97) contra caracteres (0,98) muestra una ventaja mínima, que justificamos como decisión de diseño (robusta a faltas y a texto pegado), no como resultado. **Preferencias (prueba, 20 libros):** F1 de la clase 1 de 0,57 (TF-IDF) y 0,67 (embeddings); en validación cruzada repetida 0,64±0,10 y 0,63±0,11, es decir, indistinguibles. **La mayor diferencia estuvo en la auditoría**, porque ahí hay una señal real (URL, marcas, palabras como «gratis») que cada representación captura de manera distinta; en las preferencias la diferencia entre modelos es ruido sobre etiquetas aleatorias y 20 libros (un libro cambia 5 puntos de exactitud).

4. ¿Mejoró algún clasificador a la similitud?

Lista (prueba, 20 libros, 12 positivos)	precision@5
TF-IDF + clasificador	0,60
Embeddings + clasificador	0,40
Similitud con el perfil (promedio de positivos)	0,40
Azar (proporción de 1 en prueba)	0,60

El clasificador TF-IDF superó a las otras dos listas por un libro, pero solo iguala al azar (0,60); los embeddings y la similitud quedan por debajo. Con 5 libros por lista, un acierto vale 0,20 y no podemos afirmar que ningún clasificador mejore las recomendaciones, algo esperable con etiquetas simuladas.

5. Errores encontrados y límites

Errores: (a) en el paso 6, *Una vida en palabras* (real=1) fue un falso negativo del modelo con embeddings (A=1, B=0); (b) la combinación de detectores marcó 4 libros legítimos, y ningún clasificador de oraciones detectó *«Pedí tu copia escribiendo a ventas@…test»* (otro detector lo marcó: el recall de la combinación fue 1,00); (c) la entidad «pdf» aparece entre las más frecuentes del perfil de interes=1, señal de que puede quedar algo de contaminación sin detectar; (d) la primera versión del detector de copias marcaba también el original: lo corregimos para marcar solo la copia (la sinopsis más larga), con lo que la precisión pasó de 0,75 a 1,00. **Límites:** las valoraciones son simuladas (no hay preferencias reales), solo hay 20 libros de prueba, un único lector, una muestra enriquecida con variantes que no cubren todo el catálogo, umbrales calibrados con pocas oraciones y la configuración fija que pide la consigna (sin búsqueda de hiperparámetros). Una puntuación alta es una estimación del modelo, no garantía de que el libro guste.

Uso de asistentes de IA

Usamos Claude (Claude Code) para comprender conceptos de la unidad, programar y depurar el notebook (por ejemplo la comparación de detectores y la corrección del detector de copias), generar la simulación del lector y redactar este informe a partir de los resultados ejecutados. Las cifras citadas provienen de la ejecución del notebook *TP3_grupo.ipynb*.